

Projeto Titanic

Este documento apresenta a análise à base de dados ao desastre do navio de cruzeiro, Titanic.

Breve resumo da sua história:

A construção do Titanic levou cerca de 2 anos e custou 7,5 milhões de dólares (valores da época). Com 269 metros de comprimento, 28 metros de largura e 53 metros de altura, operava com uma tripulação de 892 pessoas e poderia levar até 2435 passageiros (espalhados pelas três classes disponíveis).

Pensado para ser o mais seguro e luxuoso navio da época, foi lançado ao mar em 1911, ganhando a fama de ser “inafundável”.

O naufrágio do Titanic teve como fatores contribuintes as causas naturais (como o clima) e as causas humanas (negligência e excesso de confiança). O naufrágio matou 1502 pessoas de um total de 2224 passageiros.

Objetivo do Projeto

Este projecto tem o objectivo de determinar quais os factores relevantes para a sobrevivência dos tripulantes, quais as variáveis que tiveram maior influência na probabilidade de sobrevivência.

Esta análise inclui:

- Estatísticas descritivas
- Visualizações gráficas
- Criação de novas variáveis
- Análises comparativas

Abordagem Metodológica

- Análise Exploratória (EDA): quais os tipos de variáveis? Existem valores em falta?
- Pré-processamento: Limpeza, codificação e normalização dos dados;
- Modelagem dos dados: como tratar os valores ausentes, se os mesmos existirem, e aplicar estratégias de codificação para variáveis categóricas;
- Análise Interpretativa: quais as variáveis com mais relevância que podem indicar a probabilidade de sobrevivência?

Análise Exploratória - Visão Geral

É importante ter uma visão geral do conjunto de dados. Seguem as variáveis principais:

Variável	Descrição	Notas
Survived	Sobreviveu (0 = Não, 1 = Sim)	Target da análise preditiva
Pclass	Classe do bilhete (1 = 1ª, 2 = 2ª, 3 = 3ª)	Indicador de estatuto socioeconómico
Sex	Sexo	male, female
Age	Idade em anos	Fracionária se < 1. Estimada com .5 se necessário
SibSp	Nº de irmãos/cônjuges a bordo	
Parch	Nº de pais/filhos a bordo	
Ticket	Nº do bilhete	
Fare	Valor pago pelo bilhete	
Cabin	Número da cabine	Muitos valores em falta
Embarked	Porto de embarque (C, Q, S)	Cherbourg, Queenstown, Southampton

1. Estrutura Geral

Total de colunas: **12**

Colunas numéricas: **7**

Colunas categóricas: **5**

2. Avaliação de Dados Ausentes

Coluna	Valores em falta	Total de valores	Percentagem (%)
PassengerId	0	891	0.00%
Survived	0	891	0.00%
Pclass	0	891	0.00%
Name	0	891	0.00%
Sex	0	891	0.00%
Age	177	891	19.87%
SibSp	0	891	0.00%
Parch	0	891	0.00%
Ticket	0	891	0.00%
Fare	0	891	0.00%
Cabin	687	891	77.12%
Embarked	2	891	0.22%

2.1 **Age:** 177 valores ausentes, quase 20% da amostra

- Poderemos agrupar os valores, dependendo da análise

2.2 **Cabin:** 687 valores ausentes. É um valor muito elevado, poderá comprometer a análise

- Probabilidade de excluir esta variável

2.3 **Embarked:** 2 valores ausentes

- Podem ser imputados com o valor mais frequente (moda); poderemos também alterar esta variável para valores binários.



3. Cardinalidade (Valores Únicos)



- **Alta cardinalidade**
 - PassengerId, Name, Ticket – têm um valor elevado de valores únicos, não deverão ser úteis na modelagem de dados.
 - **Baixa cardinalidade**
 - Sex, Embarked, Pclass, Survived – baixa cardinalidade, são uma boa opção para a análise.
-

Análise Profunda da Estrutura do Dataset

Análise Univariada das Variáveis e Identificação de Valores em Falta – Age

- A distribuição das idades é positiva mas existe uma ligeira assimetria à direita. Indica, portanto que existem mais passageiros jovens. Assimetria: 0.39 e Curtose: 0.17;
- Foi verificada a existência de outliers, entre os 60 e os 80 anos;
- A média é de 29.7 e a mediana 28 anos, ou seja, não existe grande distorção;
- Para remover os valores ausentes foi aplicada a média correspondente à variável Pclass. Foi criada uma nova coluna para não alterar a original;
- Depois foi gerado um gráfico boxplot por classe, permitindo comparar as distribuições.










Análise Univariada das Variáveis e Identificação de Valores em Falta – Fare

- O objectivo é comparar o valor médio e mediano da variável Fare (tarifa) entre sobreviventes e não sobreviventes. Quem pagou mais?
- Foi verificado um outlier, o valor mais alto é 512\$. Por este motivo existe uma assimetria positiva acentuada.
- Visto que é um valor muito afastado dos restantes, é aconselhável confirmar se foi um erro tipográfico, ou se por exemplo, este valor foi pago por mais que uma pessoa.
- Foi criado um filtro e foi observado que a tarifa 512\$ foi paga por 3 pessoas da 1ª classe e embarcaram no mesmo porto. São, portanto 3 pessoas da primeira classe e os 3 sobreviveram.
- O valor 512.33 é aproximadamente 6.09x a média da 1ª classe, e aproximadamente 8.50x a mediana da 1ª classe.
- Podemos interpretar que 512 é um valor extremamente acima do valor médio praticado na 1ª classe, é um outlier claro dentro da própria categoria, que poderemos excluir ou tratar. Se este valor foi removido, a distribuição dos dados irá normalizar.
- A opção escolhida foi agrupar os valores mais alto em outra categoria, a de Luxo, e assim os valores outliers ficam “escondidos” nesta nova segmentação.
- De seguida, foram verificados os valores 0 da variável Fare e foi também concluído que são dados que não podem ser excluídos da análise, pois tratam-se de pessoas reais que não pagaram bilhete, por oferta do mesmo ou são trabalhadores do navio.
- Foi concluído então, que quem sobreviveu pagou tarifas significativamente mais altas. Isto sugere que estavam em classes mais altas, o que faz sentido, pois segundo a história do desastre a primeira classe teve melhor e directo acesso aos botes salva-vidas.
- A análise à variável Fare está assim terminada e é considerada relevante para este projecto.





🔍 Existe correlação entre as variáveis Fare, Pclass e Survived?


Fare e Pclass têm uma correlação **negativa**: quanto menor o número da classe (1ª classe), maior tende o valor a ser pago

Como foi explicado anteriormente, os passageiros da 1ª classe que pagaram tarifas mais altas, tiveram maior taxa de sobrevivência.

Pode-se dizer, portanto, que existe uma correlação **positiva** entre Fare e Survived.

📊 Análise Univariada das Variáveis e Identificação de Valores em Falta – Embarked

- Qual o porto de embarque mais frequente? Há relação entre o porto de embarque (Embarked) e a taxa de sobrevivência?
- A maioria dos passageiros embarcou em Southampton (S), seguido de Cherbourg (C) e finalmente Queenstown (Q).
- Foram verificados valores nulos, únicos e se existem linhas duplicadas; não existem linhas duplicadas e existem 3 valores únicos e 2 nulos.
- No entanto, esta variável não está normalizada, não está separada por categorias.
- Passageiros que embarcaram em (C) têm, em média, uma taxa de sobrevivência mais alta, porque pertenciam à 1ª classe, portanto, esta variável não está relacionada directamente com a sobrevivência. Mas pode ser relevante para análise, quando combinada com a Pclass e Fare.



Embarked	Frequência	Percentagem
S	644	72.44%
C	168	18.90%
Q	77	8.66%

 **Há alguma diferença clara no número de sobreviventes por classe (Pclass) e sexo (Sex), combinados?**

Sim, e muito. Segundo os dados que temos, ser mulher (e criança) era um critério de prioridade nos botes salva-vidas. Juntando esta informação às classes, podemos indicar que as mulheres da 1ª classe têm uma taxa de sobrevivência muito alta.

Análise Univariada das Variáveis e Identificação de Valores em Falta – SibSp

- Qual é a taxa de sobrevivência de passageiros que viajaram sozinhos (SibSp == 0) comparada aos que estavam com familiares?
- Passageiros que viajavam sozinhos tinham uma taxa de sobrevivência menor. No entanto grandes famílias também tinha uma taxa menor.
- Foi criada uma variável binária para a coluna SibSp para melhorar a análise dos dados, e foi verificado que, com familiares a bordo (irmãos e cônjuges), a taxa é maior. Pode indicar que laços familiares ajudaram na evacuação



 Taxa média de sobrevivência:

Sem familiares a bordo (SibSp=0): **34.54%**

Com familiares a bordo (SibSp>=1): **46.64%**

- Foi também verificada e confirmada a existência de evidência estatística de associação entre a variável SibSp e Survived (rejeitou-se H_0 = hipótese nula).

Probabilidade de sobrevivência por número de irmãos/cônjuges (SibSp):				
	SibSp	Total	Sobreviventes	Taxa_Sobrevivencia
0	0	608	210	34.539474
1	1	209	112	53.588517
2	2	28	13	46.428571
3	3	16	4	25.000000
4	4	18	3	16.666667
5	5	5	0	0
6	8	7	0	0



Análise Univariada das Variáveis e Identificação de Valores em Falta – Parch

- Qual é a taxa de sobrevivência de passageiros que viajaram sozinhos ($Parch == 0$) comparada aos que estavam com familiares?
- Relativamente à variável $Parch$, a hipótese de sobrevivência também é maior com pais e irmãos a bordo. Também existe evidência estatística de associação entre a variável $Parch$ e $Survived$ (rejeita-se H_0).

 Taxa média de sobrevivência:

Sem familiares a bordo ($Parch=0$): **34.37%**


Com familiares a bordo ($Parch \geq 1$): **51.17%**

- Quanto mais baixa é a amostra, maior é a taxa de sobrevivência; a mesma irá adaptar-se quando a amostra aumenta
- A esmagadora maioria dos sobreviventes (68.13%) não tinha pais/filhos a bordo ($Parch = 0$). A taxa de sobrevivência é mais baixa.
- Os passageiros com 1 ou 2 pais/filhos a bordo também representam uma parcela significativa dos sobreviventes.
- Valores de $Parch$ mais elevados (3 ou mais) têm um peso muito pequeno ou nulo na sobrevivência total, em parte devido ao número reduzido de observações.
- Ter pais/filhos aumenta a probabilidade para as mulheres, não para os homens; 1 pai ou filho é um valor aceitável, se for mulher aumenta 5%. Se for homem esta percentagem diminui.

 Interpretação do resultado esperado:

Parch	Total	Sobreviventes	Taxa de Sobrevivência (%)	Peso Relativo dos Sobreviventes (%)
0	678	233	34.37	~60.57% ← maioria sobreviveu sem filhos/pais
1	118	65	55.08	~16.91%
2	80	40	50	~10.40%
3	5	3	60	~0.78% ← pouco peso amostral
4	4	0	0	0.00%
5	5	1	20	~0.26%
6	1	0	0	0.00%

Probabilidade de sobrevivência por número de pais/filhos (Parch):				
	Parch	Total	Sobreviventes	Taxa_Sobrevivencia
0	0	678	233	34.365782
1	1	118	65	55.084746
2	2	80	40	50.000000
3	3	5	3	60.000000
4	4	4	0	0.0000000
5	5	5	1	20.000000
6	8	1	0	0.0000000



Parch	Sexo	Total de Sobreviventes
0	Female	153
0	Male	80
1	Female	46
1	Male	19
2	Female	30
2	Male	10
3	Female	3
5	Female	1

Parch	Sobreviventes	Peso Relativo (%)	Female	Male
0	233	68.13	153	80
1	65	19.01	46	19
2	40	11.7	30	10
3	3	0.88	3	0
4	0	0	0	0
5	1	0.29	1	0
6	0	0	0	0

Código para a nova variável FamilySize

```
df['FamilySize'] = df['SibSp'] + df['Parch']
print(df[['SibSp', 'Parch', 'FamilySize']].head())
```

Agrupar por tamanho da família e calcular a taxa de sobrevivência média


```
survival_by_family_size = df.groupby('FamilySize')['Survived'].mean().reset_index()
```

Renomear a coluna para mais clareza

```
survival_by_family_size.rename(columns={'Survived': 'SurvivalRate'}, inplace=True)
print(survival_by_family_size)
```

#Gráfico

```
plt.figure(figsize=(8,5))
sns.barplot(x='FamilySize', y='SurvivalRate', data=survival_by_family_size, palette='Blues_d')
plt.title('Taxa de Sobrevivência por Tamanho da Família')
plt.xlabel('Tamanho da Família a Bordo')
plt.ylabel('Taxa de Sobrevivência')
plt.ylim(0, 1)
plt.show()
```



 **Os passageiros com bilhetes mais caros estavam mais concentrados em determinada cabine ou local de embarque? Sabemos que Cabin tem muitos valores nulos. Existe algum padrão? Estão mais ausentes em determinada classe (Pclass)?**

- Segundo os dados apresentados, existe a probabilidade que os passageiros com bilhetes mais caros embarcaram no mesmo local de embarque, neste caso, Cherbourg. Esta informação está associada à informação indicada anteriormente, que a maioria da 1ª classe embarcou neste porto.
- Relativamente às cabines, existem muitos valores em falta, cerca de 77%, a análise não seria válida. No entanto, passageiros sem cabine registada tendem a estar nas classes mais baixas.

Gráfico Taxa de sobrevivência vs classe

Calcular taxa de sobrevivência por classe

```
survival_by_class = df.groupby('Pclass')['Survived'].mean().reset_index()
```

Gráfico com correção do warning

```
plt.figure(figsize=(6,4))
```

```
sns.barplot(x='Pclass', y='Survived', data=survival_by_class, hue='Pclass', palette='Set2',  
legend=False)
```

```
plt.title('Taxa de Sobrevivência por Classe (Pclass)')
```

```
plt.xlabel('Classe')
```

```
plt.ylabel('Taxa de Sobrevivência')
```

```
plt.ylim(0, 1)
```

```
plt.show()
```



Interpretação

- Com base nos dados histórico do Titanic, a classe com a taxa de sobrevivência mais alta é a 1ª classe, cerca de 63%.
- Ou seja, existe possibilidade da taxa variar significativamente com a classe.
- Passageiros da 3ª classe têm a menor taxa de sobrevivência, pela dificuldade de acesso aos botes salva-vidas (a 3ª classe era a última a chegar ao pontão).

Gráfico para extrair o título da variável Name

Extrair o título a partir do nome (Name)

```
df['Title'] = df['Name'].str.extract(r'\s*([^\s]+\s)\.', expand=False)
```

Propostas para codificação para as variáveis categóricas, Sex, Embarked, Pclass

Variável	Tipo	Valores únicos esperados	Estratégia recomendada
Sex	Nominal	['male', 'female']	Label Encoding ou One-Hot
Embarked	Nominal	['S', 'C', 'Q']	One-Hot Encoding
Pclass	Ordinal	[1, 2, 3]	Ordinal Encoding

- Podemos criar coluna com valores binários para a variável Sex:

```
df["Sex_encoded"] = df["Sex"].map({"female": 1, "male": 0})  
print(df[["Sex", "Sex_encoded"]].head())
```

- Aplicar One-Hot Encoding à Embarked:

```
df_encoded = pd.get_dummies(df, columns=["Embarked"], prefix="Embarked",  
drop_first=False)
```

```
| Embarked\_C | Embarked\_Q | Embarked\_S |
```

```
| ----- | ----- | ----- |
```

```
| 0      | 0      | 1      |
```

```
| 1      | 0      | 0      |
```

```
| 0      | 1      | 0      |
```

```
from sklearn.preprocessing import LabelEncoder
```

```
# Inicializar o codificador
```

```
le = LabelEncoder()
```

```
# Aplicar Label Encoding à coluna 'Embarked' e criar nova coluna
```

```
df['Embarked_code'] = le.fit_transform(df['Embarked'])
```



```
# Verificar mapeamento

print("✖ Mapeamento LabelEncoder:")

for category, code in zip(le.classes_, le.transform(le.classes_)):
    print(f"{category} → {code}")

# Verificar resultado

print(df[['Embarked', 'Embarked_code']].head())
```

Proposta para a escolha de 3 variáveis que, combinadas, podem indicar a probabilidade de sobrevivência

- **Fare, Sex e Pclass**

Interpretação

- Foi verificado nas análises anteriores que estas 3 variáveis (também poderia ser escolhida a Age), são altamente explicativas relativamente à sobrevivência.
- Sex: as mulheres tiveram prioridade no salvamento.
- Pclass: foi concluído que a 1ª classe tinha maior taxa de sobrevivência por melhor acesso ao convés.
- Fare: foi verificado que o valor do bilhete está relacionado com o acesso em primeiro lugar aos botes. No entanto, a análise aos dados usando esta variável só funciona com a combinação com a Pclass, pois ambas estão fortemente correlacionadas.
- Combinando estas três variáveis podemos supor que uma mulher jovem da 1ª classe tem maior probabilidade de sobrevivência em relação a um homem adulto da 3ª classe.
- A Age também é uma variável com algum poder para interpretação dos dados, pois indica a prioridade nos botes salva-vidas (crianças eram as primeiras). Também foram distinguidos perfis dos passageiros, por exemplo famílias jovens vs adultos sozinhos.

Conclusão

As variáveis Sex e Pclass contêm os factores com maior impacto na probabilidade de sobrevivência.

Heatmap showing the correlation matrix for the variables: Survived, Fare, Pclass, Age_Binned_Code, SibSp, Parch, and Sex_bin. The color scale ranges from -1.0 (dark blue) to 1.0 (dark red).

	Survived	Fare	Pclass	Age_Binned_Code	SibSp	Parch	Sex_bin
Survived	1	0.26	-0.34	0.095	-0.035	0.082	0.54
Fare	0.26	1	-0.55	0.1	0.16	0.22	0.18
Pclass	-0.34	-0.55	1	-0.2	0.083	0.018	-0.13
Age_Binned_Code	0.095	0.1	-0.2	1	0.14	0.19	0.044
SibSp	-0.035	0.16	0.083	0.14	1	0.41	0.11
Parch	0.082	0.22	0.018	0.19	0.41	1	0.25
Sex_bin	0.54	0.18	-0.13	0.044	0.11	0.25	1

24

Dep. Variable:	Survived	No. Observations:	891
Model:	Logit	Df Residuals:	887
Method:	MLE	Df Model:	3
Date:	Mon, 28 Jul 2025	Pseudo R-squ.:	0.3034
Time:	21:20:33	Log-Likelihood:	-413.34
converged:	True	LL-Null:	-593.33
Covariance Type:	nonrobust	LLR p-value:	1.029e-77
=====			
	coef	std err	z
			P> z
			[0.025
			0.975]
const	0.5131	0.309	1.663
Fare	0.0015	0.002	0.714
Pclass	-0.9172	0.122	-7.521
Sex_bin	2.6306	0.185	14.247

✅ Interpretação do gráfico “Correlação entre variáveis numéricas”:

- **Fare e Pclass** têm uma **correlação negativa moderada** (~ -0.55):
Passageiros da 1ª classe pagaram tarifas mais altas. Isso sugere que incluir ambas no mesmo modelo pode gerar redundância.
 - **Fare e Survived** têm uma **correlação positiva fraca** (~ 0.26):
Parece que tarifas mais altas estão associadas a maior taxa de sobrevivência, mas é uma relação **indireta** — mediada por Pclass.
 - **Pclass e Survived** têm **correlação negativa** (~ -0.34):
Passagens de 1ª classe aumentaram as chances de sobrevivência.
-

📊 Existem variáveis com potencial de falsa correlação?

- Embarked: Pode indicar uma aparente correlação com a sobrevivência; foi identificado que mais passageiros da 1ª classe embarcaram em Cherbourg. No entanto, é aconselhável usá-la combinada com a Pclass.
 - Ticket: Pouco significado real; poderão existir padrões que coincidem com grupos ou famílias.
-

📊 Interpretação das variáveis independentes:

Variável	Coeficiente (coef)	P> z	Interpretação
const	0.5131	0.096	Interceção do modelo (valor base de log-odds)
Fare	0.0015	0.475	Não é estatisticamente significativo ($p > 0.05$), ou seja, o preço pago pelo bilhete não explica bem a sobrevivência neste modelo
Pclass	-0.9172	0.000	Altamente significativo: quanto mais alta a classe (ex: de 1 para 3), menor a probabilidade de sobreviver
Sex_bin	2.6306	0.000	Extremamente significativo: o sexo influencia muito a sobrevivência; como Sex_bin = 1 representa female, isso indica que mulheres têm uma probabilidade muito maior de sobreviver

Conclusões Finais

- A Análise Exploratória e Estatística Descritiva da base de dados Titanic permitiu identificar padrões relevantes e possíveis relações entre as variáveis disponíveis, bem como a probabilidade de sobrevivência, que foi o foco principal neste estudo.
- Os principais resultados são os seguintes:
 - A idade dos passageiros tem uma distribuição assimétrica à direita: muitos adultos jovens e poucos idosos;
 - Crianças e bebês representam uma pequena percentagem da amostra, mas segundo os dados históricos, há indícios que tiveram uma taxa de sobrevivência maior;
 - Os passageiros sobreviventes pagaram, em média, mais que os não sobreviventes;
 - Foi verificado que as variáveis Fare e Pclass têm elevada correlação entre elas, no entanto, Fare e Survived têm uma correlação fraca;
 - O sexo dos passageiros tem um alto impacto na sobrevivência; as mulheres sobreviveram em maior quantidade que os homens, independentemente da sua classe. É uma variável altamente preditiva e deve ser mantida na modelagem;
 - Passageiros que viajavam sozinhos apresentam uma menor taxa de sobrevivência, no entanto, famílias numerosas também apresentam dificuldades de acesso ao convés e botes.

31 de Julho de 2025

Cátia Torrinha